엔트로피를 낮춘 DNS 터널링에 대한 임계값 방식과 로지스틱 회귀 분류기의 탐지율 비교

작성자: 김경민 · 작성일: 2026 년 10 월 14 일 · 보안 부트캠프 과제 10 (AI 와 함께 쓰는 첫 논문)

초록

DNS 터널링은 DNS 질의 이름에 데이터를 숨겨 내보내는 기법이며, 이름의 엔트로피가 높다는 점이 탐지의 단서로 쓰인다. 공격자가 엔트로피를 낮추면 이 단서에만 의존하는 탐지는 약해질 것이라는 점에 주목하여, 엔트로피 임계값 방식과 여러 특징(엔트로피, 길이, 숫자 비율, 레이블 개수)을 함께 쓰는 로지스틱 회귀 분류기의 탐지율 변화를 비교했다. 정상 질의 1,000 개와 엔트로피 단계(높음·중간·낮음)별 터널링 질의 각 1,000 개를 규칙으로 생성하고, 방어 측이 '높음' 단계만 학습한 조건에서 5 회 반복해 재현율과 오탐률을 측정했다. 높음에서 낮음까지의 재현율 하락 폭은 임계값 방식 0.997, 분류기 0.568 이었고 두 값의 차이는 5 회 평균 0.429 로, 사전에 정한 기준(0.10)을 모든 회차에서 넘어 가설은 지지되었다. 다만 분류기도 낮음 단계의 재현율이 0.395 에 그쳤고, 특징 제거 분석에서 분류기가 덜 떨어진 것은 엔트로피보다 길이와 레이블 개수 덕분인 것으로 보였다. 학습에 낮춘 형태를 포함한 탐색적 실험에서는 분류기의 낮음 재현율이 0.941 로 유지되었다. 데이터가 모두 합성이므로 결과를 실제 트래픽에 일반화할 수 없다.

1. 서론

1.1 문제의식

본 연구는 AI(머신러닝), 정보보안, 네트워크 세 분야가 함께 걸리는 주제로 DNS 터널링 탐지를 다룬다. DNS 터널링은 방화벽이 대체로 통과시키는 DNS 질의의 이름에 데이터를 실어 외부로 보내는 기법이다. 이런 질의 이름은 사람이 짓는 이름과 달리 문자가 고르게 섞여 엔트로피가 높은 경향이 있고, 이를 단서로 삼는 탐지가 연구되어 왔다 [3]. 엔트로피와 길이 같은 특징을 머신러닝 분류기에 학습시켜 터널링을 탐지하는 연구와 실무 사례도 있다 [1][2][4]. 그러나 공격자가 이름의 엔트로피를 일부러 낮추면 엔트로피 하나에 의존하는 탐지는 약해질 수 있다. 이때 여러 특징을 함께 쓰는 분류기는 얼마나 덜 약해지는가가 본 연구의 문제의식이다.

1.2 이미 알려진 것과 새로 주장하는 것

이미 알려진 것은 두 가지다. 터널링 도메인은 정상 도메인보다 문자 분포가 고르고 엔트로피가 높다 [3]. 엔트로피와 길이 등의 특징으로 학습한 분류기로 터널링을 탐지할 수 있다 [1][2][4]. 본 연구가 새로 주장하는 것은, 터널링 이름의 엔트로피를 낮출 때 임계값 방식과 분류기의 탐지율 하락 폭이 다르다는 점이다. 엔트로피를 낮춘 회피 상황에서의 동작은 [1]이 향후 연구로 남겨 둔 영역이며, 이번에 찾은 범위에서는 이 상황에서 방식별 탐지율 하락 폭을 비교한 선행 연구를 찾지 못했다(없다고 단정하지는 않는다).

1.3 가설

터널링 DNS 질의의 도메인 엔트로피를 낮추면, 엔트로피 임계값 방식의 탐지율(재현율)은 크게 떨어지지만 여러 특징을 함께 쓰는 로지스틱 회귀 분류기의 탐지율은 상대적으로 덜 떨어진다.

- 원인과 결과: 터널링 이름의 엔트로피 수준(높음·중간·낮음)이 탐지율에 영향을 주며, 그 하락 폭이 탐지 방식에 따라 다르다.
- 측정: 엔트로피는 접두사 문자열(점 제외)의 샤넌 엔트로피(bit/문자)이다. 재현율은 해당 단계의 터널링 시험 질의 중 터널링으로 판정된 비율, 오탐률은 정상 시험 질의 중 터널링으로 판정된 비율이다. 하락 폭은 높음 단계 재현율에서 낮음 단계 재현율을 뺀 값이다.
- 가설이 틀렸다면: (임계값 방식의 하락 폭 − 분류기의 하락 폭)의 5 회 평균이 0.10 미만이면 기각한다. 즉 두 방식의 하락 폭이 비슷하거나 분류기가 더 크게 떨어지면 가설은 틀린 것이다. 이 기준은 데이터 생성 전에 확정했다.
- 기간·범위: 총 5 일. 정상 1,000 개와 단계별 터널링 1,000 개로 이루어진 데이터를 회차마다 새로 만들어 5 회 반복한다.

1.4 주제 선정 과정

관심 분야(AI, 정보보안, 네트워크)에서 AI(Claude)와 함께 강의 내용과 관련된 후보 질문 열 개를 뽑았고, 세 분야가 모두 걸리는 일곱 개로 좁힌 뒤, 자료를 직접 모을 수 있는지와 기간을 기준으로 세 개를 남겼다. 검토한 후보 중 접은 것과 이유는 다음과 같다.

- Nmap 스캔 결과의 입력 형식이 LLM 의 취약 서비스 식별 정확도에 주는 영향: 정답이 강의안에 이미 있어 직접 탐구할 여지가 적다.

- ACL 복잡도가 LLM 이 만든 규칙의 오류율에 주는 영향: 강의안의 설정 예제가 정답 기준이 되어 새로 알아내는 부분이 적다.
- LLM 이 생성한 Snort 룰의 탐지율: 설치와 트래픽 재현 환경 구성에 시간이 오래 걸려 짧은 기간에 맞지 않는다.
- LLM 을 침입탐지기로 쓸 때 입력 표현이 정확도에 주는 영향: 정답 라벨이 붙은 트래픽을 100~200 개 직접 만들어야 해서 기간이 부담된다.
- 공격 패킷 캡처 분석에서 프롬프트 방식이 공격 유형 식별률에 주는 영향: 공격 재현과 캡처가 필요하고, 프롬프트 효과 연구라 네트워크·보안 깊이가 얕아진다.

최종으로 DNS 터널링 탐지를 고른 이유는, 앞의 두 후보는 정답이 강의안에 이미 있어 확인에 가까운 반면 이 주제는 정답이 없어 데이터를 직접 만들어 탐구할 수 있고, 강의에서 배운 Scapy DNS 실습의 확장이며, 세 분야가 모두 걸리고, 5 일 안에 가능한 규모이기 때문이다.

1.5 AI 와 가설을 다듬은 과정

1. 관심 분야를 말하고 Claude 에게 강의안 기반의 후보 주제 열 개를 받았다.
2. 세 분야가 모두 걸리는 후보를 다시 요청해 일곱 개로 정리했다.
3. 한 문장 가설이 가능한지, 자료 수집이 쉬운지, 기간이 짧은지를 기준으로 세 개로 압축했다.
4. 세 개를 비유로 풀어 설명받고 직접 하나를 골랐다.
5. 임계값 방식과 분류기의 차이를 되물어 확인했고, 이 연구의 AI 가 머신러닝 분류기를 뜻함을 정리했다.
6. 기간(5 일)과 데이터 규모는 Claude 의 제안을 참고해 정했다.

2. 방법

2.1 실험 설계

구분	내용
바꾼 조건	터널링 접두사의 엔트로피 단계: 높음 4.0~4.6, 중간 3.4~3.8, 낮음 2.7~3.1 (bit/문자)
고정한 조건	접두사 길이 16~40 자(세 단계 동일), 레이블 1~3 개, 특징 4 개(엔트로피·길이·숫자 비율·레이블 개수), 정상 데이터 구성, 반복

구분	내용
	시드
정상 질의	회차당 1,000 개. 일반 호스트명 700 개(서비스명·단어 조합), 해시형 정상 이름 300 개. 등록 도메인은 Tranco 상위 5,000 개에서 추출
터널링 질의	단계마다 1,000 개(회차당 3,000 개). 등록 도메인은 예약 이름(.example)
표본 수·반복	회차당 4,000 건, 5 회(시드 11·22·33·44·55), 총 20,000 건. 회차마다 데이터를 새로 생성
방식 A	임계값: 학습 데이터에서 균형 정확도가 최대인 엔트로피 값
방식 B	표준화 후 로지스틱 회귀(특징 4 개)
1 차(본 결과)	학습: 정상 500 + 높음 500. 시험: 정상 500 + 높음 500 + 중간 1,000 + 낮음 1,000. 방어 측은 낮춘 형태를 모른다고 가정
2 차(탐색적)	학습: 정상 500 + 각 단계 500. 시험: 정상 500 + 각 단계 500. 판정에는 쓰지 않음
측정값	단계별 재현율, 오탐률, 하락 폭(높음→낮음)
판정 기준	(방식 A 하락 폭 − 방식 B 하락 폭)의 5 회 평균 ≥ 0.10 이면 지지, 아니면 기각. 1 차에만 적용

2.2 데이터 생성과 특징

터널링 질의의 접두사는 문자 종류 수와 길이를 바꿔 가며 무작위로 만들고, 측정한 엔트로피가 해당 단계의 구간에 들 때까지 다시 뽑아 단계별로 정해진 엔트로피를 갖게 했다. 길이와 레이블 개수의 범위는 세 단계에서 같다. 정상 질의는 서비스명과 영단어를 조합한 호스트명과, 해시처럼 무작위로 보이는 정상 이름으로 구성했다. 네 특징은 모두 이 접두사에서만 계산했다. 따라서

Tranco 에서 가져온 등록 도메인은 질의 이름의 뒷부분을 구성할 뿐 특징과 결과 수치에는 영향을 주지 않는다.

2.3 공개 데이터의 출처

정상 질의의 등록 도메인은 Tranco 목록 [5](목록 ID N26LW, https://tranco-list.eu/top-1m.csv.zip)에서 2026 년 10 월 14 일에 받아 상위 5,000 개 중 회차마다 1,000 개를 무작위로 추출했다. 원본 목록은 저장소에 포함하지 않고 출처와 ID 만 기록했다.

2.4 설계 변경 기록

- 본 실행 전에 AI(Claude)가 합성 데이터로 시험 실행을 1 회 했다(시드 901·902, 800 건 × 2). 임계값 방식이 설계상 크게 하락할 것으로 예상됨을 이때 인지했으나 1 차 설계는 바꾸지 않았고, 이 시험 결과는 본 결과에서 제외했다.
- 본 실행 전에 두 가지를 스크립트에 반영했다. 2 차 탐색적 실험 옵션을 추가했고(조건은 1 차 실행 전에 확정), 정상 도메인 목록의 헤더 줄을 건너뛰는 처리를 넣었다. 1 차 출력이 옵션 추가 전과 같음을 시험 출력의 전후 비교로 확인했다.
- '수상한 도메인 1,000 개'는 단계마다 1,000 개로 해석했다.
- 본 실행 이후 가설 문장, 판정 기준, 실험 스크립트(run_experiment.py)는 바꾸지 않았다. 요약표와 특징 제거 분석 스크립트는 본 실행 뒤에 추가했으나 exp1, exp2 폴더의 파일은 수정하지 않고 analysis 폴더에만 결과를 저장했다.

3. 결과

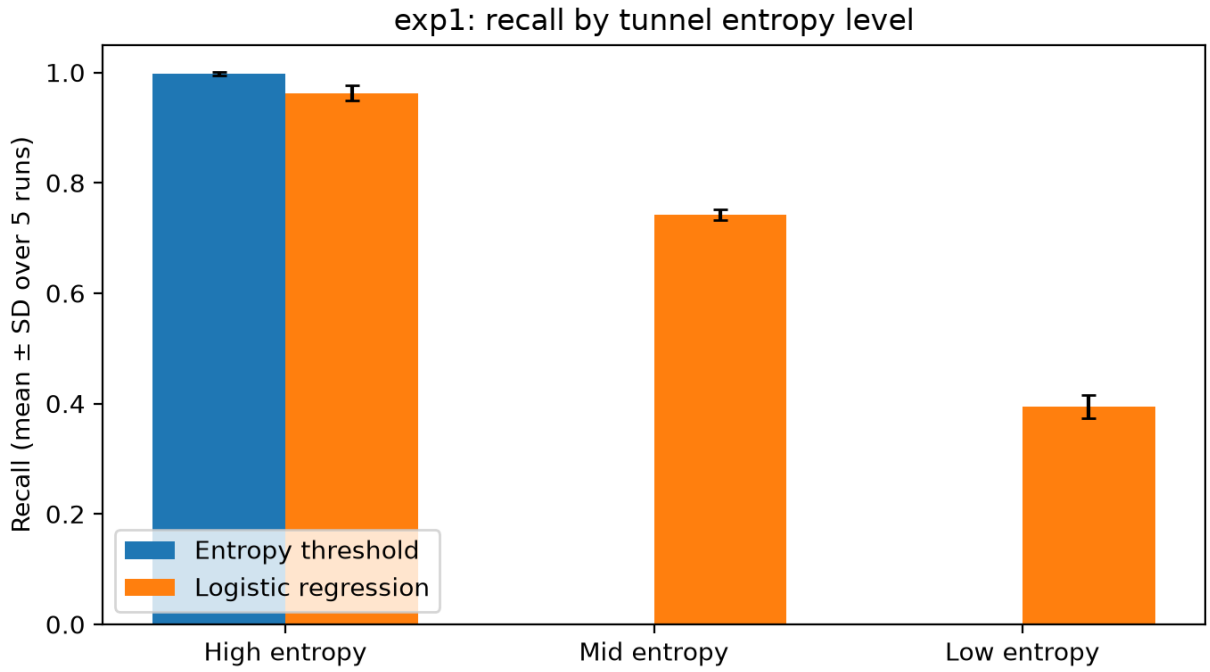
3.1 1 차 실험 (본 결과)

표 1 은 방어 측이 높음 단계만 학습한 조건에서 5 회 반복한 결과의 평균 ± 표준편차이다.

방식	높음 재현율	중간 재현율	낮음 재현율	오탐률	하락 폭(높음→낮음)
임계값 방식	0.997 ± 0.003	0.000 ± 0.000	0.000 ± 0.000	0.069 ± 0.009	0.997 ± 0.003
로지스틱 회귀	0.963 ± 0.013	0.742 ± 0.010	0.395 ± 0.021	0.053 ± 0.008	0.568 ± 0.031

표 1. 1 차 실험 결과 (5 회 평균 ± 표준편차)

회차별 (임계값 방식 하락 폭 – 분류기 하락 폭)은 0.410, 0.436, 0.417, 0.482, 0.401 이고 평균은 0.4292 이다. 사전에 정한 기준 0.10 을 모든 회차에서 넘었으므로 판정은 지지이다. 단계별 재현율 그래프는 재현 패키지의 analysis 폴더(recall_exp1.png)에 있다.



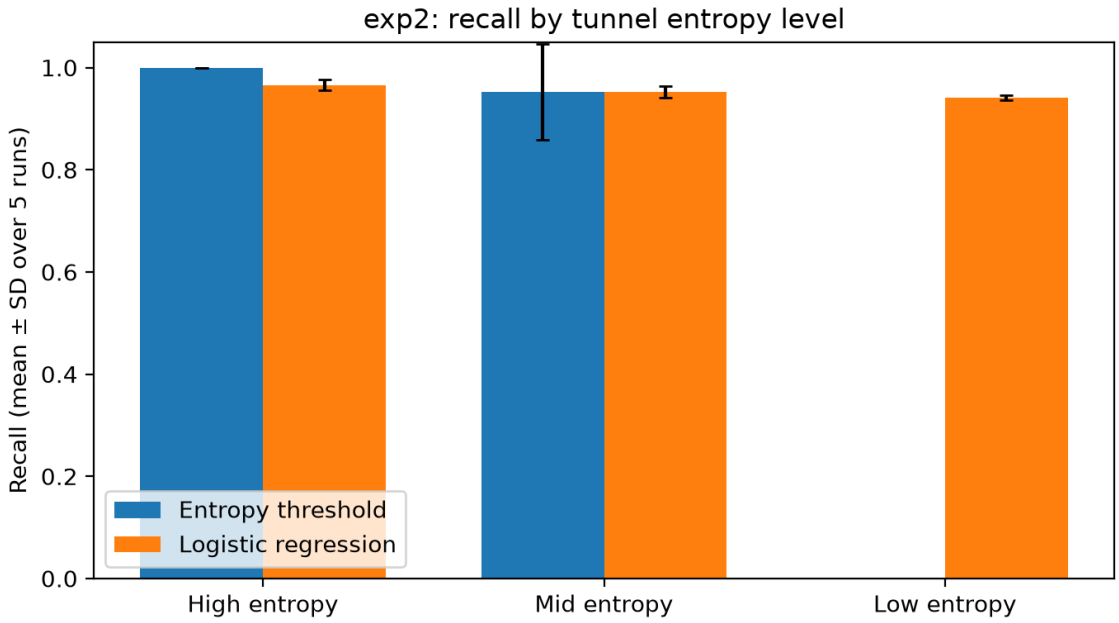
3.2 2 차 실험 (탐색적, 판정에 쓰지 않음)

표 2 는 학습에 높음·중간·낮음 터널링을 모두 포함한 조건의 결과이다.

방식	높음 재현율	중간 재현율	낮음 재현율	오탐률	하락 폭(높음→낮음)
임계값 방식	1.000 ± 0.000	0.953 ± 0.093	0.000 ± 0.000	0.299 ± 0.018	1.000 ± 0.000
로지스틱 회귀	0.966 ± 0.011	0.952 ± 0.011	0.941 ± 0.005	0.112 ± 0.006	0.024 ± 0.007

표 2. 2 차 실험 결과 (5 회 평균 ± 표준편차)

임계값 방식의 중간 단계 재현율은 회차 4 에서 0.786 으로, 다른 회차(0.984~1.000)보다 낮았다. 그래프는 analysis 폴더의 recall_exp2.png 에 있다.



3.3 특징 제거 분석 (사후 탐색적)

분류기가 어떤 특징에 기대었는지 보기 위해, 같은 원자료와 같은 학습·시험 분할에서 특징 조합만 바꾸어 다시 학습했다(5 회 평균). 전체 특징 조합은 본 실험의 저장값과 최대 차이 0 으로 일치했다.

1 차 특징 조합	높음	중간	낮음	오탐률
전체 특징(본 실험과 동일)	0.963	0.742	0.395	0.053
엔트로피만	1.000	0.000	0.000	0.090
엔트로피 제외	0.939	0.880	0.820	0.051
길이 제외	0.996	0.491	0.000	0.070
숫자 비율 제외	0.966	0.720	0.365	0.053
레이블 개수 제외	0.978	0.432	0.001	0.075

표 3. 1 차 조건의 특징 제거 분석 (단계별 재현율과 오탐률)

2 차 특징 조합	높음	중간	낮음	오탐률
전체 특징(본 실험과 동일)	0.966	0.952	0.941	0.112
엔트로피만	1.000	1.000	1.000	0.760
엔트로피 제외	0.986	0.955	0.914	0.129
길이 제외	1.000	0.972	0.775	0.472
숫자 비율 제외	0.966	0.951	0.942	0.121
레이블 개수 제외	0.970	0.936	0.946	0.207

표 4. 2 차 조건의 특징 제거 분석 (단계별 재현율과 오탐률)

4. 논의

4.1 가설대로 나온 부분과 다르게 나온 부분

가설대로 나온 부분은, 엔트로피를 낮추었을 때 탐지율이 떨어지는 폭이 임계값 방식보다 분류기에서 작았다는 점이다. 표 1 의 하락 폭은 임계값 방식 0.997, 분류기 0.568 이고, 두 값의 차이는 모든 회차에서 사전 기준 0.10 을 넘었다(0.401~0.482). 따라서 이 데이터는 가설을 뒷받침한다.

다만 가설과 다르거나 예상보다 약하게 나온 부분이 있다. 첫째, 분류기도 낮음 단계에서 재현율이 0.395 에 그쳐 터널링의 약 60%를 놓쳤다. 따라서 덜 떨어졌다고는 할 수 있어도 엔트로피 회피에 잘 견뎠다고 말할 수는 없다. 둘째, 임계값 방식의 재현율이 0 이 된 것은 임계값을 높음 데이터로 정하는 학습 구조에서 예상되는 결과이며, 새로운 발견으로 보기는 어렵다. 셋째, 오탐률은 분류기(0.053)가 임계값 방식(0.069)보다 낮았다. 넷째, 2 차에서 임계값 방식은 낮춘 형태를 학습에 포함해도 낮음 단계를 한 건도 탐지하지 못했고, 중간 단계를 잡는 대신 오탐률이 0.299 로 올랐다. 이는 이 합성 데이터에서 엔트로피 값 하나로는 낮음 단계의 터널링과 정상 질의를 구분하기 어렵다는 뜻으로 읽힌다.

4.2 다르게 나온 이유의 검토

첫째는 학습 범위이다. 학습에 낮춘 형태를 포함하자 분류기의 낮음 재현율이 0.395 에서 0.941 로 올랐으므로, 학습 범위가 결과에 큰 영향을 준 것은 데이터로 확인된다.

둘째는 분류기가 엔트로피 이외의 특징에 의존했을 가능성이다. 특징 제거 분석(표 3)에서 엔트로피만 쓴 분류기는 임계값 방식처럼 중간과 낮음에서 재현율이 0 이었다. 반대로 엔트로피를 제외하고 나머지 세 특징으로 학습하면 낮음 재현율이 0.820 으로, 전체 특징을 쓸 때(0.395)보다 높았다. 길이를 제외하면 낮음 재현율이 0.000, 레이블 개수를 제외하면 0.001 로 떨어졌다. 따라서 분류기가 낮춘 형태를 일부 탐지한 것은 엔트로피보다 길이와 레이블 개수 덕분이었던 것으로 보인다. 높음 단계만 학습한 조건에서 엔트로피 특징이 오히려 낮은 구간으로의 일반화를 방해했을 가능성이 있으나, 이는 관찰된 패턴에 대한 추정이며 이 실험만으로 확정할 수 없다. 이 분석은 결과를 본 뒤 수행한 탐색적 분석이므로 가설 판정에는 쓰지 않았다.

셋째는 데이터 생성 방식이다. 터널링 질의의 길이와 레이블 개수 분포를 연구자가 정했고, 이 설정이 분류기의 성능에 영향을 주었을 수 있다. 선행 연구 [4]는 로지스틱 회귀의 정밀도가 낮았다고 보고했으나, 본 연구는 정밀도가 아닌 오탐률을 측정했고 데이터도 달라 직접 비교하지 않는다.

4.3 가설 수정 여부

가설은 고치지 않았다. 본 실행 전에 확정한 가설 문장과 판정 기준을 결과를 본 뒤에도 바꾸지 않았다. 결과를 본 뒤 추가한 분석은 모두 탐색적 분석으로 표시하고 판정에 쓰지 않았다. 새로 생긴 질문, 즉 분류기가 낮춘 형태를 일부 탐지한 것이 엔트로피 이외의 특징 때문이라는 해석은 별도의 사전 설계로 검증해야 할 후속 과제로 남긴다.

4.4 결론

이 합성 데이터와 설정에서, 방어 측이 엔트로피가 높은 터널링 질의로만 학습했을 때 도메인 엔트로피를 낮춘 터널링에 대한 탐지율 하락 폭은 로지스틱 회귀가 임계값 방식보다 작았다(0.568 대 0.997). 따라서 가설은 지지되었다. 그러나 분류기의 재현율도 낮음 단계에서 0.395 까지 떨어졌고, 분류기가 덜 떨어진 것은 엔트로피가 아니라 길이와 레이블 개수 같은 다른 특징 덕분인 것으로 보인다. 또한 학습에 낮춘 형태를 포함하면 분류기는 낮음 단계에서도 재현율 0.941 을 유지했으므로, 탐지 성능은 방식의 종류만큼이나 학습 데이터가 회피 형태를 포함하는지에

좌우되었다. 엔트로피 하나로 판단하는 방식은 학습 범위와 관계없이 낮음 단계를 탐지하지 못했다.

4.5 한계

이 연구로 말할 수 없는 것이 있다. 모든 데이터가 합성이다. 터널링 질의의 길이, 레이블 개수, 엔트로피 구간을 연구자가 정했고, 정상 질의의 접두사도 규칙으로 생성했다. 정상 도메인은 공개 목록(Tranco)에서 추출했으나 분석 특징은 접두사에서만 계산했으므로 이 목록은 결과 수치에 영향을 주지 않았다. 따라서 실제 DNS 트래픽에서도 같은 결과가 나온다고 말할 수 없다. 분석한 특징은 네 개이고 모델은 로지스틱 회귀 하나뿐이어서 다른 모델이나 특징 조합에서는 결과가 달라질 수 있다. 다섯 번의 반복은 데이터를 새로 생성하여 반복한 것이지 서로 다른 실제 환경에서의 반복이 아니며, 통계적 검정은 하지 않았다. 판정 기준 0.10 은 연구자가 임의로 정한 값이다. 임계값 방식의 재현율 하락은 학습 구조상 예상된 결과이다. 특징 제거 분석은 결과를 본 뒤 수행한 탐색적 분석이므로 가설 판정의 근거로 사용할 수 없다.

참고문헌

[1] Khodjaeva, Y., Zincir-Heywood, N., & Zincir, I. (2022). Can We Detect Malicious Behaviours in Encrypted DNS Tunnels Using Network Flow Entropy? Journal of Cyber Security and Mobility, 11(3), 461–496. https://doi.org/10.13052/jcsm2245-1439.1135

연결: 엔트로피를 특징에 추가하면 머신러닝 분류기의 탐지 성능이 달라짐을 실험으로 보인다(로지스틱 회귀 포함 5 종 비교). 다만 도메인 이름이 아니라 암호화 DNS 트래픽 흐름의 엔트로피를 쓴 연구이므로, 가설의 엔트로피를 특징으로 쓰는 분류기라는 큰 틀만 뒷받침한다. 또한 회피·적대적 상황에서의 동작을 향후 연구로 남겼다는 점에서 본 연구의 새 주장과 이어진다.

[2] Berg, A., & Forsberg, D. (2019). Identifying DNS-tunneled traffic with predictive models. arXiv:1906.11246. https://arxiv.org/abs/1906.11246

연결: 이름 길이와 이름 엔트로피 등 여러 특징으로 분류기를 학습시켜 터널링을 탐지한다. 가설의 여러 특징을 함께 쓰는 분류기 부분을 뒷받침하며, 실험으로 검증한 연구이다.

[3] Born, K., & Gustafson, D. (2010). Detecting DNS tunnels using character frequency analysis. arXiv:1004.4358. https://arxiv.org/abs/1004.4358

연결: 정상 도메인과 달리 터널링 도메인은 문자 분포가 고르다는 것을 실증한다. 가설의 엔트로피가 높을수록 수상하다는 전제를 뒷받침한다.

[4] Ansari, Z. (2026). Novel AI Techniques for DNS Tunnel Security. Infoblox Blog. https://www.infoblox.com/blog/security/novel-ai-techniques-for-dns-tunnel-security/

연결: 엔트로피를 포함한 여러 특징을 결합한 분류기가 실제 운영 환경에서 쓰이는 사례(2026 년 2 월 5 일 게시)로, 가설의 분류기 방식이 현실적으로 쓰인다는 점을 뒷받침하는 보조 자료이다. 기업 블로그이며 성능 수치는 업체가 직접 보고한 것이다.

[5] Le Pochat, V., Van Goethem, T., Tajalizadehkhoob, S., Korczyński, M., & Joosen, W. (2019). Tranco: A Research-Oriented Top Sites Ranking Hardened Against Manipulation. NDSS 2019. https://doi.org/10.14722/ndss.2019.23386

연결: 가설을 뒷받침하는 문헌이 아니라, 정상 질의의 등록 도메인을 추출한 공개 목록(Tranco)의 출처 문헌이다.

목록에서 뺀 자료. 특허 문서는 학술 연구가 아니라 방법 설명서여서, 제품 홍보나 일반 해설 성격의 보안 업체 블로그 세 곳은 엔트로피 3.5 이상이면 의심이라는 기준이 검증 없이 반복되어서, 출처가 불분명한 백과사전식 항목 하나와 AI 도구용 설명 페이지 하나는 문헌이 아니어서 뺐다. 저자와 게시일을 확인할 수 없고 실험이 없는 개인 블로그 글(사전 단어 기반 인코딩으로 낮은 엔트로피 통신을 만든다는 내용)도 뺐다. [1]의 확장 전 버전인 석사 학위논문은 내용이 겹쳐 학술지 논문만 남겼고, [1]의 문헌 조사에서 소개된 Das 외(2017)는 원문을 확인하지 못해 넣지 않았다.

출처를 확인한 방법. AI(Claude)가 웹 검색으로 제시한 문헌을 제목으로 검색해 실물이 존재하는지 확인했고, 저자·연도·DOI 를 서지 정보와 대조했다. [1]은 출판사 PDF 에서 권(호)과 쪽수를 확인했고, [2][3]은 arXiv 초록 페이지로 저자와 연도를 확인했으며, [4]는 작성자가 페이지에서 저자·제목·게시일을 직접 확인했다. [2][3]은 심사 보증이 없는 프리프린트이고 [4]는 기업 블로그이므로, 학술지 논문인 [1]을 핵심 근거로 삼았다. [2][3]은 초록 중심으로 확인했고 전문은 읽지 않았다.

부록 A. 재현 방법

환경. Windows, PowerShell, Python 3.15.0, numpy 2.5.4, scikit-learn 1.9.1, matplotlib 3.11.2.

패키지 구성. README.md, requirements.txt, DATA_SOURCE.txt, 실행 스크립트(run_experiment.py), 재확인 스크립트(verify.py), 분석 스크립트(summarize.py, ablation.py), 원자료와 결과(exp1/, exp2/), 요약표·그래프·특징 제거 결과(analysis/), 이 논문.

실행 순서.

1. 패키지를 설치한다: python -m pip install -r requirements.txt, python -m pip install matplotlib
2. 정상 도메인 목록(Tranco, 목록 ID N26LW)을 받아 tranco.csv 로 저장한다. 원본 목록은 패키지에 포함하지 않았다.
3. 1 차 실행: python run_experiment.py --tranco tranco.csv --tranco-date 2026-10-14 --out exp1
4. 1 차 재확인: python verify.py --out exp1
5. 2 차 실행과 재확인: python run_experiment.py --tranco tranco.csv --tranco-date 2026-10-14 --train-levels all --out exp2, 이어서 python verify.py --out exp2
6. 요약표·그래프·특징 제거 분석: python summarize.py --exp exp1, python summarize.py --exp exp2, python ablation.py --exp exp1, python ablation.py --exp exp2

결과 확인 방법. verify.py 의 모든 줄이 OK 이고 마지막 줄이 '결과: 모두 일치'이면 원자료 건수(회차당 4,000 건, 총 20,000 건), 엔트로피 값, 저장된 재현율·오탐률이 서로 맞는 것이다. exp1/results/summary.json 에서 두 하락 폭의 차이 평균이 0.4292, 판정이 '지지'로 나오면 본 결과와 같다.

참고. 분석 특징은 접두사에서만 계산되므로, 같은 시드에서 상위 5,000 개를 쓰는 한 정상 도메인 목록의 내용이 달라도 결과 수치는 같게 나온다. 점검용으로 임의로 만든 목록을 써서도 같은 수치가 나옴을 확인했다. 실행 순서는 저장소의 커밋 기록으로 확인할 수 있다(실행 전 c9b6d16, 1 차 결과 d136019, 2 차 결과 f28b971, 분석 스크립트 2193a72, 분석 결과 a968cfb).

부록 B. AI 활용과 직접 판단

AI(Claude)에게 맡긴 일.

- 관심 분야 안의 후보 주제 제안과 비교, 세 후보를 쉬운 비유로 설명
- 가설 초안, 측정 방법과 기각 조건 초안, 판정 기준 0.10 의 제안(임의로 정한 값)
- 실험 설계, 데이터 생성·분석 스크립트(run_experiment.py, verify.py, summarize.py, ablation.py) 작성, 합성 데이터 시험 실행 1 회
- 선행 연구 검색과 서지 정보 초안
- 결과 해석 초안과 이 논문의 초안 작성

작성자가 직접 판단한 일.

- 최종 주제의 선택과 이유: 정답이 강의안에 이미 있는 후보를 피하고, 정답을 직접 만들어 탐구할 수 있는 DNS 터널링을 골랐다. AI 가 이 이유를 잘못 이해했을 때 작성자가 바로잡았다.
- 기간(5 일)과 데이터 규모의 확정
- 판정 기준을 바꾸지 않고 AI 가 제안한 값 그대로 쓰기로 한 결정
- 시험 실행에서 드러난 설계의 약점을 알고도 기준을 고치지 않고, AI 가 제안한 탐색적 2 차 실험을 추가하기로 한 결정
- 실험을 본인 컴퓨터에서 직접 실행하고 재확인 결과를 확인했으며, 단계마다 깃허브에 저장
- 참고문헌 링크를 직접 열어 저자와 연도를 확인했고, [4]의 저자·제목·게시일을 직접 확인

논문 초안은 AI 가 작성했으며, 본문의 모든 수치는 작성자가 직접 실행한 결과(exp1, exp2, analysis 폴더)에서 가져왔다.

AI 와 나의 판단 3 줄.

1. AI 는 후보 주제 제안, 실험 설계와 코드, 문헌 검색, 결과 해석과 논문 초안을 맡았다.
2. 나는 주제와 기간·규모를 정하고, 판정 기준을 결과를 보기 전에 고정했으며, 실험을 직접 돌려 결과를 확인했다.
3. 설계의 약점(임계값 방식의 붕괴는 예상된 결과)을 알게 된 뒤에도 기준을 고치지 않고 탐색적 2 차 실험을 추가하기로 했으며, 참고문헌은 링크를 직접 열어 확인했다.